

INSTITUTO TECNOLÓGICO DE COSTA RICA — ESCUELA DE MATEMÁTICA

CE-1111: Análisis Numérico para Ingeniería | II Semestre, 2026

Método del Gradiente Conjugado

Portafolio Computacional — Bloque 2

Sistemas de Ecuaciones Lineales

Steven Aguilar Alvarez

David Cordero Zúñiga

Emeron Wallace Marín

s.aguilar.3@estudiantec.cr

d.cordero.1@estudiantec.cr

e.wallace.1@estudiantec.cr

1. Introducción

El método del Gradiente Conjugado (*Conjugate Gradient*, CG) es un método iterativo para aproximar la solución del sistema de ecuaciones lineales

$$A\mathbf{x} = \mathbf{b}, \quad A \in \mathbb{R}^{n \times n}, \quad \mathbf{x}, \mathbf{b} \in \mathbb{R}^n, \quad (1)$$

en el caso en que A es simétrica y definida positiva. A diferencia de los métodos iterativos estacionarios estudiados previamente en el curso —Jacobi y Gauss–Seidel—, los cuales generan la sucesión $\mathbf{x}^{(k+1)} = T\mathbf{x}^{(k)} + \mathbf{c}$ a partir de una descomposición fija $A = L + D + U$, el método CG pertenece a la familia de los *métodos de subespacios de Krylov*. En cada iteración se construye una nueva dirección de búsqueda conjugada, respecto de A , con todas las direcciones generadas anteriormente. Como consecuencia directa de esta construcción, se obtiene el siguiente resultado fundamental, que se demuestra en la literatura clásica (véase la sección de Referencias, [1, 2]):

Observación 1.1. En aritmética exacta, el método del Gradiente Conjugado converge a la solución exacta de (1) en, a lo sumo, n iteraciones.

El interés práctico del método radica en que, para sistemas grandes y dispersos —como los que surgen al discretizar ecuaciones diferenciales mediante diferencias finitas—, el residuo suele alcanzar una magnitud aceptable en un número de iteraciones considerablemente menor que n . Nótese, además, que el método no requiere almacenar ni factorizar la matriz A : basta con poder evaluar productos de la forma $A\mathbf{v}$.

2. Descripción del método

2.1. Formulación variacional del problema

Proposición 2.1. Sea $A \in \mathbb{R}^{n \times n}$ simétrica y definida positiva. Entonces $\mathbf{x}^* \in \mathbb{R}^n$ satisface $A\mathbf{x}^* = \mathbf{b}$ si y solo si $\mathbf{x}^*$ es el minimizador global de la función cuadrática

$$\varphi(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T A \mathbf{x} - \mathbf{b}^T \mathbf{x}. \quad (2)$$

Justificación. Calculando el gradiente de φ se obtiene $\nabla \varphi(\mathbf{x}) = A\mathbf{x} - \mathbf{b}$, de modo que $\nabla \varphi(\mathbf{x}^*) = \mathbf{0}$ si y solo si $A\mathbf{x}^* = \mathbf{b}$. Por otra parte, el Hessiano de φ es la propia matriz A , que es definida positiva por hipótesis; en consecuencia, φ es estrictamente convexa y todo punto crítico es, necesariamente, un mínimo global único. $\square$

De esta manera, el problema lineal (1) queda planteado, de forma equivalente, como un problema de optimización sin restricciones sobre φ .

2.2. Residuo y direcciones conjugadas

En la iteración k se define el **residuo** como

$$\mathbf{r}^{(k)} := \mathbf{b} - A\mathbf{x}^{(k)} = -\nabla\varphi(\mathbf{x}^{(k)}). \quad (3)$$

Un método de descenso simple avanzaría directamente en la dirección de $\mathbf{r}^{(k)}$; sin embargo, este esquema —conocido como *descenso de gradiente*— exhibe típicamente un patrón de convergencia en zigzag cuando A está mal condicionada, pues direcciones sucesivas tienden a ser casi paralelas.

Definición 2.1. Sean $\mathbf{p}, \mathbf{q} \in \mathbb{R}^n$ no nulos. Se dice que $\mathbf{p}$ y $\mathbf{q}$ son A -conjugados si

$$\mathbf{p}^T A \mathbf{q} = 0. \quad (4)$$

El método CG evita el comportamiento en zigzag construyendo una sucesión de direcciones de búsqueda $\mathbf{p}^{(0)}, \mathbf{p}^{(1)}, \dots$ mutuamente A -conjugadas en el sentido de (4). Puede demostrarse que, al avanzar sucesivamente a lo largo de direcciones conjugadas, la iteración k -ésima resulta óptima —en el sentido de φ — dentro de todo el subespacio generado por $\mathbf{p}^{(0)}, \dots, \mathbf{p}^{(k-1)}$, de modo que ninguna dirección anterior necesita corregirse nuevamente.

2.3. Construcción de la iteración

Sea $\mathbf{x}^{(0)}$ una aproximación inicial arbitraria. Se inicializa

$$\mathbf{r}^{(0)} = \mathbf{b} - A\mathbf{x}^{(0)}, \quad \mathbf{p}^{(0)} = \mathbf{r}^{(0)}. \quad (5)$$

Paso 1 (tamaño de paso óptimo). Dada la dirección $\mathbf{p}^{(k)}$, se busca $\alpha_k \in \mathbb{R}$ que minimice la restricción unidimensional $g(\alpha) := \varphi(\mathbf{x}^{(k)} + \alpha \mathbf{p}^{(k)})$. Derivando respecto de α e igualando a cero,

$$g'(\alpha) = \left(\mathbf{p}^{(k)}\right)^T \left(A\mathbf{x}^{(k)} + \alpha A\mathbf{p}^{(k)} - \mathbf{b}\right) = -\left(\mathbf{p}^{(k)}\right)^T \mathbf{r}^{(k)} + \alpha \left(\mathbf{p}^{(k)}\right)^T A \mathbf{p}^{(k)} = 0,$$

de donde se obtiene

$$\alpha_k = \frac{\left(\mathbf{p}^{(k)}\right)^T \mathbf{r}^{(k)}}{\left(\mathbf{p}^{(k)}\right)^T A \mathbf{p}^{(k)}} = \frac{\left(\mathbf{r}^{(k)}\right)^T \mathbf{r}^{(k)}}{\left(\mathbf{p}^{(k)}\right)^T A \mathbf{p}^{(k)}}, \quad (6)$$

donde la segunda igualdad se sigue de que, en el método CG, $\left(\mathbf{p}^{(k)}\right)^T \mathbf{r}^{(k)} = \left(\mathbf{r}^{(k)}\right)^T \mathbf{r}^{(k)}$ para todo k —propiedad que se obtiene por inducción a partir de la construcción misma de $\mathbf{p}^{(k)}$ —. Como A es definida positiva, el denominador de (6) es estrictamente positivo siempre que $\mathbf{p}^{(k)} \neq \mathbf{0}$, de modo que α_k está bien definido.

Paso 2 (actualización de la aproximación y el residuo). Se define

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha_k \mathbf{p}^{(k)}. \quad (7)$$

Multiplicando ambos lados de (7) por $-A$ y sumando $\mathbf{b}$, se sigue directamente que el residuo puede actualizarse sin necesidad de recalcular $\mathbf{b} - A\mathbf{x}^{(k+1)}$:

$$\mathbf{r}^{(k+1)} = \mathbf{r}^{(k)} - \alpha_k A \mathbf{p}^{(k)}. \quad (8)$$

Paso 3 (nueva dirección conjugada). La siguiente dirección se construye como una combinación del nuevo residuo y la dirección anterior,

$$\mathbf{p}^{(k+1)} = \mathbf{r}^{(k+1)} + \beta_k \mathbf{p}^{(k)}, \quad (9)$$

donde β_k es el único escalar que garantiza la A -conjugación $(\mathbf{p}^{(k+1)})^T A \mathbf{p}^{(k)} = 0$. Imponiendo dicha condición sobre (9) se obtiene

$$\beta_k = \frac{(\mathbf{r}^{(k+1)})^T \mathbf{r}^{(k+1)}}{(\mathbf{r}^{(k)})^T \mathbf{r}^{(k)}}. \quad (10)$$

En consecuencia, las ecuaciones (6)–(10) determinan de manera completa la iteración del método. El proceso se detiene cuando el residuo es suficientemente pequeño en norma euclídea, es decir, cuando

$$\|A\mathbf{x}^{(k)} - \mathbf{b}\|_2 < \text{tol}, \quad (11)$$

el mismo criterio de parada empleado para Jacobi y Gauss–Seidel en este bloque del portafolio.

3. Condiciones sobre la matriz de coeficientes

Definición 3.1. Una matriz $A \in \mathbb{R}^{n \times n}$ es **simétrica definida positiva** (SPD) si:

- (i) $A = A^T$, (simetría)
- (ii) $\mathbf{v}^T A \mathbf{v} > 0$ para todo $\mathbf{v} \in \mathbb{R}^n \setminus \{\mathbf{0}\}$. (definición positiva)

Estas dos condiciones son indispensables para el método CG, por las razones siguientes.

- *Simetría.* Si A no fuera simétrica, el gradiente de la función cuadrática (2) sería $\frac{1}{2}(A + A^T)\mathbf{x} - \mathbf{b}$, y la equivalencia con $A\mathbf{x} = \mathbf{b}$ establecida en la Proposición 2.1 dejaría de cumplirse.
- *Definición positiva.* Garantiza que φ sea estrictamente convexa (de modo que el punto crítico sea efectivamente un mínimo, y no un máximo o un punto de silla) y, adicionalmente, que el denominador de (6) sea siempre estrictamente positivo, evitando divisiones por cero o avances en una dirección de ascenso.

Nota. Cuando A es invertible pero no simétrica definida positiva, es posible aplicar el método al sistema normal $A^T A \mathbf{x} = A^T \mathbf{b}$, dado que $A^T A$ es siempre SPD si A es invertible; sin embargo, esta transformación puede deteriorar el condicionamiento numérico del problema, por lo que en la práctica suelen preferirse variantes como GMRES para matrices no simétricas. Ambas alternativas quedan fuera del alcance de este documento.

4. Algoritmo

Se presenta a continuación el pseudocódigo del método, siguiendo la misma convención de entradas y salidas utilizada para Jacobi y Gauss–Seidel en este bloque: dados A , $\mathbf{b}$, una aproximación inicial $\mathbf{x}^{(0)}$, la tolerancia tol y el número máximo de iteraciones iterMax , el algoritmo retorna la aproximación $\mathbf{x}_k$, el error $\text{er}_k = \|A\mathbf{x}_k - \mathbf{b}\|_2$, el número de iteraciones k efectivamente realizadas, y el indicador de convergencia $\text{conv} \in \{0, 1\}$.

Algoritmo 1 Gradiente Conjugado**Entrada:** $A \in \mathbb{R}^{n \times n}$ (SPD), $\mathbf{b} \in \mathbb{R}^n$, $\mathbf{x}^{(0)} \in \mathbb{R}^n$, tol , iterMax **Salida:** $\mathbf{x}_k$, er_k , k , conv

```

1:  $\mathbf{x} \leftarrow \mathbf{x}^{(0)}$ 
2:  $\mathbf{r} \leftarrow \mathbf{b} - A\mathbf{x}$ 
3:  $\mathbf{p} \leftarrow \mathbf{r}$ 
4:  $\text{er} \leftarrow \|\mathbf{r}\|_2$ 
5:  $k \leftarrow 0$ ,  $\text{conv} \leftarrow \text{falso}$ 
6: mientras  $\text{er} > \text{tol}$  y  $k < \text{iterMax}$  hacer
7:    $\mathbf{q} \leftarrow A\mathbf{p}$  ▷ único producto matriz–vector de la iteración
8:    $\alpha \leftarrow \frac{\mathbf{r}^T \mathbf{r}}{\mathbf{p}^T \mathbf{q}}$ 
9:    $\mathbf{x} \leftarrow \mathbf{x} + \alpha \mathbf{p}$ 
10:   $\mathbf{r}_{\text{nuevo}} \leftarrow \mathbf{r} - \alpha \mathbf{q}$ 
11:   $\beta \leftarrow \frac{\mathbf{r}_{\text{nuevo}}^T \mathbf{r}_{\text{nuevo}}}{\mathbf{r}^T \mathbf{r}}$ 
12:   $\mathbf{p} \leftarrow \mathbf{r}_{\text{nuevo}} + \beta \mathbf{p}$ 
13:   $\mathbf{r} \leftarrow \mathbf{r}_{\text{nuevo}}$ 
14:   $\text{er} \leftarrow \|A\mathbf{x} - \mathbf{b}\|_2$ 
15:   $k \leftarrow k + 1$ 
16: fin mientras
17: si  $\text{er} \leq \text{tol}$  entonces
18:    $\text{conv} \leftarrow \text{verdadero}$ 
19: fin si
20: retornar  $\mathbf{x}$ ,  $\text{er}$ ,  $k$ ,  $\text{conv}$ 

```

Observación 4.1. Como en Jacobi y Gauss–Seidel, en ningún paso del Algoritmo 1 se calcula una matriz inversa ni se resuelve un sistema lineal auxiliar: cada iteración requiere, exclusivamente, un producto matriz–vector ($A\mathbf{p}$) y un número fijo de productos internos, lo cual hace al método particularmente eficiente cuando A es de gran tamaño y dispersa.

5. Ejemplo completo

Se ilustra el método resolviendo el sistema $A\mathbf{x} = \mathbf{b}$ con

$$A = \begin{pmatrix} 4 & -1 & 0 & 0 \\ -1 & 4 & -1 & 0 \\ 0 & -1 & 4 & -1 \\ 0 & 0 & -1 & 4 \end{pmatrix}, \quad \mathbf{b} = (1, 2, 3, 4)^T, \quad \mathbf{x}^{(0)} = (0, 0, 0, 0)^T. \quad (12)$$

Nótese que A es simétrica y estrictamente diagonalmente dominante por filas, pues en cada fila el valor absoluto del elemento diagonal (4) excede la suma de los valores absolutos de los demás elementos de esa fila; esta condición es suficiente para garantizar que A es definida positiva. Se concluye, entonces, que A es SPD y el método del Gradiente Conjugado es aplicable.

Inicialización

De (5), como $\mathbf{x}^{(0)} = \mathbf{0}$, se tiene

$$\mathbf{r}^{(0)} = \mathbf{p}^{(0)} = \mathbf{b} = (1, 2, 3, 4)^T, \quad \|\mathbf{r}^{(0)}\|_2 = \sqrt{30} \approx 5.477226. \quad (13)$$

Iteración 1

Se calcula primero

$$A \mathbf{p}^{(0)} = (2, 4, 6, 13)^T, \quad \left(\mathbf{p}^{(0)}\right)^T A \mathbf{p}^{(0)} = 80, \quad \left(\mathbf{r}^{(0)}\right)^T \mathbf{r}^{(0)} = 30. \quad (14)$$

Por lo tanto, de (6),

$$\alpha_0 = \frac{30}{80} = 0.375000. \quad (15)$$

Aplicando (7) y (8) se obtiene

$$\mathbf{x}^{(1)} = (0.375000, 0.750000, 1.125000, 1.500000)^T, \quad (16)$$

$$\mathbf{r}^{(1)} = (0.250000, 0.500000, 0.750000, -0.875000)^T, \quad \left\|\mathbf{r}^{(1)}\right\|_2 \approx 1.280869. \quad (17)$$

Entonces, de (10),

$$\beta_0 = \frac{1.640625}{30} \approx 0.054688, \quad (18)$$

y, por (9), la nueva dirección conjugada resulta

$$\mathbf{p}^{(1)} = (0.304688, 0.609375, 0.914063, -0.656250)^T. \quad (19)$$

Iteración 2

Análogamente,

$$A \mathbf{p}^{(1)} = (0.609375, 1.218750, 3.703125, -3.539063)^T, \quad \left(\mathbf{p}^{(1)}\right)^T A \mathbf{p}^{(1)} \approx 6.635742, \quad (20)$$

de donde

$$\alpha_1 = \frac{1.640625}{6.635742} \approx 0.247241. \quad (21)$$

Se sigue que

$$\mathbf{x}^{(2)} = (0.450331, 0.900662, 1.350993, 1.337748)^T, \quad (22)$$

$$\mathbf{r}^{(2)} = (0.099338, 0.198675, -0.165563, 0.000000)^T, \quad \left\|\mathbf{r}^{(2)}\right\|_2 \approx 0.277040, \quad (23)$$

con lo cual

$$\beta_1 = \frac{0.076751}{1.640625} \approx 0.046782, \quad \mathbf{p}^{(2)} = (0.113592, 0.227183, -0.122802, -0.030700)^T. \quad (24)$$

Iteración 3

De manera análoga a las iteraciones anteriores,

$$A \mathbf{p}^{(2)} = (0.227183, 0.917942, -0.687689, 0.000000)^T, \quad \left(\mathbf{p}^{(2)}\right)^T A \mathbf{p}^{(2)} \approx 0.318796, \quad (25)$$

$$\alpha_2 = \frac{0.076751}{0.318796} \approx 0.240753, \quad (26)$$

$$\mathbf{x}^{(3)} = (0.477679, 0.955357, 1.321429, 1.330357)^T, \quad (27)$$

$$\mathbf{r}^{(3)} = (0.044643, -0.022321, 0.000000, 0.000000)^T, \quad \left\|\mathbf{r}^{(3)}\right\|_2 \approx 0.049912, \quad (28)$$

$$\beta_2 = \frac{0.002491}{0.076751} \approx 0.032459, \quad \mathbf{p}^{(3)} = (0.048330, -0.014947, -0.003986, -0.000996)^T. \quad (29)$$

Iteración 4

Finalmente,

$$A\mathbf{p}^{(3)} = (0.208267, -0.104133, 0.000000, 0.000000)^T, \quad \left(\mathbf{p}^{(3)}\right)^T A\mathbf{p}^{(3)} \approx 0.011622, \quad (30)$$

$$\alpha_3 = \frac{0.002491}{0.011622} \approx 0.214354, \quad (31)$$

$$\mathbf{x}^{(4)} = (0.488038, 0.952153, 1.320574, 1.330144)^T, \quad \left\|\mathbf{r}^{(4)}\right\|_2 \approx 0. \quad (32)$$

Como el residuo se anula (salvo error de redondeo), el proceso se detiene en $k = 4$.

Resumen de la convergencia

k	α_{k-1}	β_{k-1}	$\left\ \mathbf{r}^{(k)}\right\ _2$	$\mathbf{x}^{(k)T}$
0	—	—	5.477226	(0.000000, 0.000000, 0.000000, 0.000000)
1	0.375000	0.054688	1.280869	(0.375000, 0.750000, 1.125000, 1.500000)
2	0.247241	0.046782	0.277040	(0.450331, 0.900662, 1.350993, 1.337748)
3	0.240753	0.032459	0.049912	(0.477679, 0.955357, 1.321429, 1.330357)
4	0.214354	—	≈ 0	(0.488038, 0.952153, 1.320574, 1.330144)

Se observa que el método alcanza la convergencia en exactamente $k = 4$ iteraciones, cantidad que coincide con la dimensión del sistema ($n = 4$), tal como lo predice la teoría enunciada en la Observación 1.1. La aproximación final,

$$\mathbf{x}^{(4)} \approx (0.488038, 0.952153, 1.320574, 1.330144)^T, \quad (33)$$

coincide, hasta el orden de la precisión de máquina, con la solución exacta de (12) obtenida mediante un método directo, es decir,

$$\left\|A\mathbf{x}^{(4)} - \mathbf{b}\right\|_2 = \mathcal{O}(10^{-16}).$$

Referencias

- [1] G. H. Golub y C. F. Van Loan, *Matrix Computations*, 4.^a ed. Baltimore, MD, USA: Johns Hopkins University Press, 2013.
- [2] J. R. Shewchuk, *An Introduction to the Conjugate Gradient Method Without the Agonizing Pain*, Pittsburgh, PA, USA: Carnegie Mellon University, 1994.
- [3] R. L. Burden y J. D. Faires, *Análisis Numérico*, 7.^a ed. México: Thomson Learning, 2002.
- [4] J. P. Soto Quirós, *Apuntes del curso CE-1111 — Análisis Numérico para Ingeniería*, Escuela de Matemática, Instituto Tecnológico de Costa Rica, Cartago, Costa Rica, 2026.